

Olist Brazilian E-commerce

*Pipeline décisionnel complet — De la donnée brute
à la recommandation mesurable*

Réalisé par :

Hafsa Abbar • Halima Anejari • Imane Raiss

Phase 1 : Problème & KPIs

Phase 2 : Audit

Phase 3 : EDA

Phase 4 : Modélisation

Phase 5 : Dashboard

Phase 6 : Décision & A/B Test

PLAN DE LA DATA STORY

01 Contexte & Problème

Question décisionnelle, domaine métier, enjeux

02 KPI Tree & Business Case

Objectifs stratégiques → métriques opérationnelles + ROI

03 Audit & Qualité des Données

Cartographie, complétude, biais, Data Dictionary

04 Exploration (EDA) & Stats

Distributions, corrélations, outliers, tests statistiques

05 Segmentation & Modélisation

RFM + K-Means · 3 modèles ML · SHAP · Comparaison

06 Dashboard, Décision & A/B Test

5 vues décisionnelles · 3 recommandations · Plan expérimental

Contexte & Problème Métier

Marketplace brésilienne Olist — 2016 à 2018 — 9 sources combinées

Qui est Olist ?

Plus grande marketplace brésilienne, Olist connecte des milliers de petits marchands à des consommateurs dans 27 états.

Notre dataset couvre plus de 100 000 commandes réelles sur 2 ans, issues de 9 tables relationnelles (commandes, paiements, avis, produits, géolocalisation...).

Deux sources enrichies :

- ① Données transactionnelles Olist (Kaggle)
- ② Traductions catégories PT → EN

Question Décisionnelle Centrale

Quels sont les leviers actionnables pour réduire le taux de churn client et maximiser la valeur vie client (LTV) sur la plateforme Olist ?

Sous-questions :

- Quels segments clients sont les plus à risque de churn ?
- La livraison tardive dégrade-t-elle la satisfaction ?
- Quelles catégories génèrent le meilleur NPS ?
- Peut-on prédire la satisfaction avant livraison ?

KPI Tree & Business Case

Des objectifs stratégiques aux métriques opérationnelles — ROI estimé sur données réelles

Maximiser Revenu & LTV

Chiffre d'Affaires

Taux de Rétention

NPS / Satisfaction

R\$ 137

Ticket Moyen

> 6 000

Nb Cmd/mois

96.9%

Taux Churn

3.1%

Repeat Rate

4.09/5

Score Moyen

92.2%

Livr. OnTime

Business Case — Scénario ROI (réduction churn -10%)

CA Total

R\$ 13.6M

Clients uniques

99 441

Clients récupérés

~9 642

Revenu additionnel


R\$ 1.32M

Impact CA

+9.7%

Audit & Qualité des Données

Cartographie · Complétude · Biais · Gaps · Data Dictionary



Biais géographique : São Paulo = 41.9% des clients — à pondérer dans les analyses

Stratégie : imputation médiane par catégorie + chaîne vide
NLP

9 Tables

sources cartographiées

~1M lignes

données brutes combinées

0


doublons complets (commandes)

8 195

commandes sans avis client

Exploration & Analyse Statistique (EDA)

Distributions · Corrélations · Outliers · Tests formels



Mann-Whitney U

p < 0.001

Livraison tardive → baisse score
significative

Kruskal-Wallis

p < 0.001

Montant varie selon le mode de paiement

Chi² Indépendance

p < 0.001

Statut livraison dépend de la région

t-test Student

p = 0.12

Taille commande n'impacte pas la
satisfaction




Segmentation & Modélisation ML

RFM · K-Means · 3 Modèles · SHAP · Comparaison

04

Segmentation Clients — RFM + K-Means (K=4)


Recency · Frequency · Monetary — 99 441 clients segmentés



Champions Recency : 45 j Freq : 3.2× Monetary : R\$ 412 Programme VIP · Fidélisation · Ambassadeurs	Réguliers Recency : 120 j Freq : 1.5× Monetary : R\$ 185 Relance email · Cross-sell ciblé
One-Shot Recency : 280 j Freq : 1× Monetary : R\$ 98 Onboarding · Offre 2e achat · Relance J+30	À Risque Recency : 380 j Freq : 1.8× Monetary : R\$ 290 Win-back urgent · Promo 15% ciblée

Modélisation Prédictive — Comparaison des Modèles

Objectif : prédire `review_score ≤ 2` (insatisfaction) · Validation croisée k-fold · Tuning hyperparamètres




	Régression Logistique				Baseline
	AUC: 0.71	F1: 0.63	Prec: 0.61	Rec: 0.65	
	Random Forest				Bon
	AUC: 0.83	F1: 0.76	Prec: 0.78	Rec: 0.74	
	XGBoost ✨ Meilleur				Optimal
	AUC: 0.87	F1: 0.81	Prec: 0.83	Rec: 0.79	

Feature Engineering

delivery_delta · freight_ratio · n_sellers ·
payment_type_encoded · state_encoded · hour_bin

Interprétabilité — SHAP Values (XGBoost)

Comprendre les décisions du modèle · Global & Local · Confiance du jury non-technique



Interprétation SHAP

delivery_delta**0.312**

Le retard de livraison est le facteur #1. +3 jours de retard → probabilité d'insatisfaction ×2.1

freight_ratio**0.145**

Frais de port > 30% du total → signal fort d'insatisfaction potentielle

n_sellers**0.082**

Commandes multi-vendeurs → coordination plus complexe → plus de risques

Modèle local**Local**

Pour chaque commande, SHAP explique individuellement la prédiction du modèle



Dashboard, Décision & A/B Test

5 vues décisionnelles · 3 leviers · Plan expérimental

05

Dashboard Décisionnel Interactif — 5 Vues

Streamlit / Power BI — accessible en ligne · Profils : Direction, Opérations, Marketing

Vue Direction

Direction

CA mensuel, taux de rétention, NPS global, revenu par état

Vue Opérations

Opérations

Livraisons tardives par région, délais par vendeur, SLA heatmap

Vue Marketing

Marketing

Segments RFM, top catégories, taux de repeat purchase, campagnes

Vue Prédictive

Data Science

Score de risque d'insatisfaction en temps réel par commande

Vue A/B Testing

Tous profils

Suivi en live des KPIs du test, intervalles de confiance, p-value

3 Recommandations Actionnables — Classées par Impact

Justification quantitative · Métriques de suivi post-décision définies

01

Réduire les livraisons tardives (7.8% → < 3%)

↑ +0.85 pt Review Score

Mann-Whitney (p<0.001) : chaque jour de retard coûte -0.17 pt de satisfaction. Action : SLA vendeurs renforcés, alertes proactives transporteurs, pénalités sur délais.

📌 Cible : Score 4.35/5 — Suivi : review_score hebdomadaire

02

Convertir les clients One-Shot (62.8% → repeat rate 13%)

↑ +R\$ 1.32M CA

62 430 clients n'ont commandé qu'une fois. Programme de relance automatique (J+30, J+60) avec offre personnalisée par catégorie achetée. Conversion cible 10% = 6 243 clients réguliers.

📌 Cible : Repeat rate 13.1% — Suivi : cohort mensuelle

03

Réactiver le segment 'À Risque' (7 386 gros acheteurs)

↑ +R\$ 215K récupéré

Clients à fort panier (R\$ 290 avg) absents depuis > 1 an. Campagne win-back ciblée : email personnalisé + promo 15%. Si 20% réactivés → 1 477 commandes × R\$ 290 = R\$ 428K (net promo = R\$ 215K).

📌 Cible : Réactivation 20% — Suivi : open rate, conversion

Plan A/B Test — Protocole Expérimental Complet

Test prioritaire : Programme de relance J+30 pour segment One-Shot

Protocole du Test

Hypothèse H0 :	L'envoi d'une offre J+30 n'améliore pas le repeat purchase rate
Hypothèse H1 :	L'offre J+30 augmente le taux de repeat purchase ($\alpha = 0.05$)
Groupe(s) :	Contrôle (50%) vs Traitement (50%)
Taille échantillon :	~12 000 clients (puissance 80%)
Durée :	60 jours (J+30 envoi → J+30 suivi)
Métriques 1° :	Repeat purchase rate
Métriques 2° :	CA par client, open rate, CTR
Test stat :	Test z-proportion (bilatéral)

Résultats Attendus

Repeat rate contrôle :	3.1%
Repeat rate traitement :	≥ 6.5% (+3.4 pts)
Impact CA estimé :	+R\$ 1.32M / an
Seuil de significativité :	p < 0.05

Métriques de Suivi Post-Décision

- Repeat purchase rate (hebdo)
- CA moyen par client réactivé
- Taux de désabonnement email
- NPS post-campagne (enquête J+45)
- ROI campagne vs coût envoi

Pipeline Décisionnel Complet

Impact Financier Total Estimé : + R\$ 2.12M (+15.6% du CA actuel)

Livraisons tardives

−7.8 pts retard

+R\$ 580K

Clients One-Shot

→ Repeat +10%

+R\$ 1.32M

Segment À Risque

Win-back 20%

+R\$ 215K

9 Sources

auditées

4 Tests

statistiques

3 Modèles

comparés

4 Segments

RFM clients

5 Vues

dashboard

1 Plan

A/B Test